

Kierunek: Informatyka Stosowana (IST)
Specjalność: Projektowanie Systemów Informatycznych (PSI)

PRACA DYPLOMOWA
MAGISTERSKA

Metoda wczesnego wykrywania choroby Alzheimera

Maria Markowiak

Opiekun pracy
Dr hab. inż. Adrianna Koziarkiewicz, prof. uczelni

Słowa kluczowe: choroba Alzheimera, wczesne wykrywanie, selektywna klasyfikacja, spłotowe sieci neuronowe, obrazowanie MRI, testy neuropsychologiczne

Streszczenie

Praca dotyczy opracowania metody wczesnego wykrywania choroby Alzheimera z wykorzystaniem selektywnej fuzji danych neuropsychologicznych i obrazowania MRI. W przeglądzie literatury przeanalizowano aktualnie stosowane typy danych w diagnostyce choroby Alzheimera oraz porównano metody unimodalne i multimodalne pod względem ich skuteczności, inwazyjności i przydatności klinicznej. Na podstawie tej analizy opracowano dwustopniowy model klasyfikacyjny. Pierwszy etap wykorzystuje wyniki testów neuropsychologicznych (MMSE, CDR, GDS) do wstępnej klasyfikacji pacjentów. Wprowadzono próg pewności klasyfikacji $\tau = 0,85$, który warunkuje kierowanie pacjentów do drugiego etapu. Etap drugi, oparty na analizie obrazów MRI za pomocą splotowych sieci neuronowych, wykorzystywany jest wyłącznie dla przypadków trudnych diagnostycznie, poniżej progu pewności τ . Takie podejście pozwala ograniczyć wykorzystanie kosztownych i czasochłonnych badań MRI do około 28% pacjentów. Model został przetestowany na danych ze zbioru ADNI. Osiągnięto wysoką skuteczność klasyfikacji (100% czułości dla pary AD vs. CN, ponad 92% czułości dla MCI vs. CN i 87% dla AD vs. MCI). Wyniki te są porównywalne lub lepsze niż metody wielomodalne, przy znacznie niższych kosztach. Proponowana metoda jest dobrze dostosowana do zastosowań klinicznych, szczególnie w badaniach przesiewowych.

Abstract

This thesis focuses on developing a method for early detection of Alzheimer's disease using a selective fusion of neuropsychological data and MRI imaging. The literature review analyzed the currently used data types in Alzheimer's disease diagnostics and compared unimodal and multimodal methods in terms of their effectiveness, invasiveness, and clinical applicability. Based on this analysis, a two-stage classification model was developed. The first stage utilizes the results of neuropsychological tests (MMSE, CDR, GDS) for the initial classification of patients. A classification confidence threshold of $\tau = 0.85$ was introduced to determine whether a patient should proceed to the second stage. The second stage, based on MRI image analysis using convolutional neural networks, is applied only to diagnostically challenging cases that fall below the confidence threshold τ . This approach reduces the use of costly and time-consuming MRI scans to approximately 28% of patients. The model was evaluated on the ADNI dataset. High classification performance was achieved (100% sensitivity for AD vs. CN, over 92% sensitivity for MCI vs. CN, and 87% for AD vs. MCI). These results are comparable to or better than multimodal methods, while significantly reducing costs. The proposed method is well suited for clinical applications, particularly for screening purposes.

Spis treści

1	Wstęp	1
1.1	Wprowadzenie do tematu	1
1.2	Przedmiot pracy	1
1.3	Cel pracy	2
1.4	Zakres pracy	2
1.5	Struktura pracy	2
2	Przegląd literatury	5
2.1	Typy danych wykorzystywanych w wykrywaniu choroby Alzheimera	6
2.2	Podjęcia oparte o jedno źródło danych w wykrywaniu choroby Alzheimera . .	11
2.2.1	Metody unimodalne oparte na obrazowaniu MRI	12
2.2.2	Metody oparte na innych pojedynczych źródłach danych	16
2.3	Podjęcia oparte o wiele źródeł danych w wykrywaniu choroby Alzheimera . .	18
2.3.1	Strategie fuzji danych w klasyfikatorach multimodalnych	18
2.3.2	Metody multimodalne wykrywania choroby Alzheimera	20
2.4	Kryteria oceny skuteczności klasyfikatorów	21
2.5	Wnioski z przeglądu literatury	23
3	Proponowana metoda	27
3.1	Formalizacja problemu klasyfikacji	27
3.2	Schemat proponowanej metody	29
3.2.1	Etap I. Klasyfikacja na podstawie testów poznawczych	30
3.2.2	Etap II. Selektowna klasyfikacja wspomagana obrazowaniem MRI . . .	33
3.2.3	Strategia fuzji i klasyfikacja końcowa	36
4	Organizacja badań	39
4.1	Zbiór danych	39
4.1.1	Dane neuropsychologiczne	39
4.1.2	Obrazy MRI	40
4.1.3	Charakterystyka zbioru danych	40
4.2	Przetwarzanie danych	43
4.2.1	Przetwarzanie danych testów poznawczych	43
4.2.2	Przetwarzanie obrazów MRI	44
4.3	Budowa i ocena modeli klasyfikacyjnych	46
4.3.1	Podział zbioru danych	46
4.3.2	Dobór hiperparametrów modeli w etapie I	47

4.3.3	Dobór hiperparametrów splotowych sieci neuronowych w etapie II	49
4.3.4	Metryki oceny skuteczności klasyfikacji	50
4.3.5	Uwagi implementacyjne	51
5	Wyniki badań	53
5.1	Ocena klasyfikatorów w etapie I	53
5.1.1	Wybór najlepszego klasyfikatora	53
5.1.2	Dobór progu decyzyjnego	60
5.2	Wyniki klasyfikacji obrazów MRI w etapie II	63
5.2.1	Dobór hiperparametrów w splotowych sieciach neuronowych	63
5.2.2	Zestawienie wyników splotowych sieci w różnych płaszczyznach i agregacja predykcji	66
5.3	Wyniki modelu dwustopniowego	67
5.3.1	Porównanie wariantów metody	67
5.3.2	Końcowe wyniki proponowanego modelu dwustopniowego	69
5.4	Porównanie proponowanej metody z wynikami z literatury	70
5.4.1	Porównanie z metodami jednomodalnymi	72
5.4.2	Porównanie z metodami wielomodalnymi	72
5.4.3	Podsumowanie wyników proponowanej metody z metodami z literatury	72
6	Zakończenie	75
6.1	Wnioski z przeprowadzonych badań	75
6.2	Perspektywy dalszych prac	76
	Bibliografia	76
	Spis rysunków	83
	Spis tabel	85

1. Wstęp

Wraz ze starzeniem się społeczeństw choroby neurodegeneracyjne stają się jednym z największych wyzwań współczesnej medycyny. Szczególnie istotnym problemem jest choroba Alzheimera, która znacząco obniża jakość życia milionów osób na całym świecie. Pomimo intensywnych badań wciąż brakuje skutecznych metod leczenia, dlatego kluczowe znaczenie ma opracowanie nowoczesnych narzędzi umożliwiających jak najwcześniejszą diagnozę, pozwalającą wdrożyć interwencje opóźniające postęp choroby.

1.1. Wprowadzenie do tematu

Choroba Alzheimera jest najczęstszą postacią demencji i jednym z największych wyzwań zdrowotnych starzejącego się społeczeństwa. Szacuje się, że na świecie żyje obecnie około 57 milionów osób dotkniętych demencją, a każdego roku przybywa 10 milionów nowych przypadków. Choroba Alzheimera odpowiada za 60-70% tych zachorowań [65]. Wraz z wydłużaniem się życia i starzeniem populacji liczba chorych będzie gwałtownie rosła. Prognozy WHO (*World Health Organization*) [64] wskazują na wzrost przypadków demencji do około 78 milionów w roku 2030 i aż 139 milionów do roku 2050. Skala tego zjawiska będzie przekładać się na ogromne obciążenie systemów opieki zdrowotnej oraz rodzin osób chorych, które wraz z postępem choroby stają się coraz mniej samodzielne.

Wczesne rozpoznanie choroby Alzheimera umożliwia szybkie wdrożenie terapii spowalniającej rozwój demencji, poprawę jakości życia oraz lepsze planowanie opieki i leczenia [3]. W praktyce diagnoza choroby Alzheimera stawiana jest często dopiero przy zaawansowanych objawach otępiennych, gdy w mózgu zaszły już nieodwracalne zmiany. Standardowe metody diagnostyczne są czasochłonne, kosztowne i często wymagają złożonych badań klinicznych, takich jak neuroobrazowanie czy inwazyjna analiza płynu mózgowo-rdzeniowego [44].

Choroba Alzheimera została opisana po raz pierwszy w roku 1906 przez niemieckiego neuropatologa Aloisa Alzheimera jako "nietypowa choroba kory mózgowej" [37]. Po ponad stu latach badań nad tym schorzeniem, współczesna medycyna nadal nie dysponuje skutecznym lekarstwem, a leczenie ma głównie charakter objawowy. Z tego powodu rośnie znaczenie badań nad wczesnym wykryciem choroby Alzheimera, w których szczególną rolę odgrywają zaawansowane techniki informatyczne. Coraz więcej prac naukowych koncentruje się na zastosowaniu algorytmów uczenia maszynowego do wspomagania specjalistów w wykrywaniu zmian neurodegeneracyjnych we wczesnym stadium choroby.

1.2. Przedmiot pracy

Niniejsza praca skupia się na zastosowaniu metod sztucznej inteligencji i uczenia maszynowego do klasyfikacji pacjentów we wczesnej diagnostyce choroby Alzheimera na podstawie danych z testów poznawczych i obrazowania mózgu.

1.3. Cel pracy

Celem pracy jest opracowanie i zweryfikowanie skuteczności autorskiej metody wczesnego wykrywania choroby Alzheimera, wykorzystującej techniki sztucznej inteligencji i uczenia maszynowego. Proponowane rozwiązanie ma być możliwe do zastosowania w warunkach klinicznych, stanowiąc kompromis pomiędzy wysoką czułością diagnozy a kosztami badań przesiewowych. W pracy zaprojektowano metodę dwustopniową, w której dane z prostszych, nieinwazyjnych badań są wykorzystywane do wstępnej diagnozy pacjentów, a badania neuroobrazowe stosowane są warunkowo dla przypadków wymagających dalszej weryfikacji. Opracowane podejście zostało poddane ocenie porównawczej względem rozwiązań znanych z literatury.

1.4. Zakres pracy

Zakres pracy obejmuje opracowanie i zweryfikowanie informatycznej metody wspomagającej wczesne wykrywanie choroby Alzheimera. W pierwszym etapie przeprowadzono szczegółowy przegląd literatury, obejmujący medyczne metody wykrywania Alzheimera oraz aktualne podejścia wykorzystujące sztuczną inteligencję w diagnostyce.

Na podstawie analizy literatury, opracowano autorską, dwustopniową metodę wczesnego wykrywania choroby Alzheimera, opartą na analizie wyników testów poznawczych oraz warunkowym zastosowaniu neuroobrazowania. Pozyskano zbiory danych, przeprowadzono ich wstępne przetwarzanie, a następnie przeprowadzono serię eksperymentów oraz walidację skuteczności proponowanej metody na danych testowych. Uzyskane wyniki poddano analizie porównawczej z rezultatami znanymi z literatury.

1.5. Struktura pracy

Praca została podzielona na sześć rozdziałów.

Rozdział pierwszy stanowi wprowadzenie do tematu. Omówiono w nim aktualny stan wiedzy w zakresie diagnostyki choroby Alzheimera oraz zarysowano ogólne tło problemu. Następnie sformułowano cel i zakres pracy.

Drugi rozdział zawiera obszerny przegląd literatury, opisujący aktualny stan wiedzy na temat choroby Alzheimera i dostępnych metod jej wczesnego wykrywania z wykorzystaniem technik informatycznych. Omówiono dotychczasowe podejścia jednomodalne i multimodalne badawcze oraz wykorzystywane rodzaje danych w diagnostyce choroby Alzheimera. Analiza literatury służyła zidentyfikowaniu ograniczeń i niedoskonałości dotychczasowych badań i rozwiązań.

W rozdziale trzecim przedstawiono zaproponowaną metodę wczesnego wykrywania choroby Alzheimera z uwzględnieniem jej struktury oraz sposobu przetwarzania danych. Omówiono wykorzystywane algorytmy uczenia maszynowego stosowane w metodzie.

Rozdział czwarty zawiera szczegółowy opis części eksperymentalnej pracy. Przedstawiono w nim informacje o wykorzystanych zbiorach danych, sposobie ich przetwarzania, konfiguracji modeli wraz z metrykami ich oceny.

Rozdział piąty prezentuje wyniki przeprowadzonych eksperymentów oraz analizę porównawczą z istniejącymi rozwiązaniami znanymi z literatury.

Rozdział szósty zawiera podsumowanie pracy, przedstawia wnioski płynące z przeprowadzonych eksperymentów, weryfikację osiągnięcia celu pracy oraz wskazuje na dalsze perspektywy rozwoju pracy.

2. Przegląd literatury

Choroba Alzheimera od lat stanowi przedmiot zainteresowania środowisk medycznych i informatycznych. W kontekście informatyki i analizy danych, szczególne znaczenie ma rozwój metod umożliwiających automatyczne wykrywanie choroby na podstawie wielowymiarowych danych, takich jak testy poznawcze, neuroobrazowanie, biomarkery z krwi czy badania genetyczne.

Niniejszy przegląd literatury przedstawia istniejące podejścia do diagnozy choroby Alzheimera z wykorzystaniem technik uczenia maszynowego oraz sztucznej inteligencji. Podejścia te są następnie analizowane pod kątem efektywności, kosztu i dostępności danych wejściowych. Celem przeglądu jest zidentyfikowanie ograniczeń istniejących metod oraz określenie, czy istnieje potrzeba opracowania nowego podejścia, uwzględniającego te ograniczenia, potencjalnie realnego w wykorzystaniu jako narzędzie wspierające proces diagnostyczny.

W ramach niniejszego przeglądu podjęto próbę odpowiedzi na następujące pytania badawcze:

1. *Jakie rodzaje danych wykorzystuje się we wczesnej diagnostyce choroby Alzheimera? Jakie są ich główne zalety i ograniczenia poszczególnych typów?*
2. *Jakie podejścia oparte na pojedynczym źródle danych cechują się najwyższą skutecznością we wczesnym wykrywaniu choroby Alzheimera?*
3. *Jakie korzyści przynoszą metody multimodalne w diagnostyce choroby Alzheimera i z jakimi wyzwaniem wiąże się ich stosowanie?*
4. *Jakie metryki oceny najczęściej wykorzystuje się do oceny skuteczności klasyfikatorów w diagnostyce choroby Alzheimera?*

Odpowiedzi na powyższe pytania pozwolą na analizę możliwości i ograniczeń aktualnie istniejących metod wczesnej diagnozy choroby Alzheimera oraz na wskazanie obszarów, gdzie istnieje potrzeba stworzenia nowego, możliwego do zastosowania w praktyce podejścia diagnostycznego.

Kolejne podrozdziały w niniejszym przeglądzie literatury odpowiadają bezpośrednio na wcześniej postawione pytania badawcze. Typy danych stosowanych w diagnozie choroby Alzheimera omówiono w podrozdziale 2.1. Skuteczność i wyzwania podejść jednomodalnych i wielomodalnych opisano kolejno w podrozdziałach 2.2 i 2.3. Najczęściej stosowane metryki oceny skuteczności klasyfikatorów przedstawiono w podrozdziale 2.4.

W przeglądzie skupiono się głównie na pracach wykorzystujących dane z ogólnodostępnej bazy danych ADNI (*Alzheimer's Disease Neuroimaging Initiative*) [4], co pozwala na bardziej rzetelne porównywanie wyników uzyskanych w różnych badaniach. Pojedyncze przedstawione badania korzystały również ze zbiorów danych OASIS (*Open Access Series of Imaging Studies*)

[48]. Analizowane były przede wszystkim prace, które klasyfikowały pacjentów do trzech grup klinicznych:

- **CN** (*Cognitively Normal*) - osoby zdrowo poznawcze,
- **MCI** (*Mild Cognitive Impairment*) - osoby z łagodnymi zaburzeniami poznawczymi,
- **AD** (*Alzheimer's Disease*) - osoby z klinicznie rozpoznaną chorobą Alzheimera.

Podział ten jest szeroko stosowany w badaniach nad neurodegeneracją, ponieważ odzwierciedla rzeczywisty przebieg choroby. Umożliwia on zarówno identyfikację pacjentów chorych, jak i osób w stanie pośrednim, co jest istotne dla wczesnej diagnozy i możliwości wdrożenia działań zapobiegawczych oraz spowalniających postęp choroby Alzheimera.

Wiele publikacji zostało odrzuconych na etapie selekcji ze względu na niespełnianie powyższych kryteriów porównywalności - część z nich nie opierała się na danych dostępnych publicznie (takich jak ADNI, OASIS), a inne ograniczały się wyłącznie do klasyfikacji binarnej (CN vs. AD) z pominięciem klasy pośredniej MCI. Prace te nierzadko osiągały wysoką skuteczność, ale nie odzwierciedlają rzeczywistej złożoności diagnozowania klinicznego, zwłaszcza w przypadku wczesnego wykrywania choroby Alzheimera.

2.1. Typy danych wykorzystywanych w wykrywaniu choroby Alzheimera

Choroba Alzheimera po raz pierwszy została opisana w 1906 r. przez doktora Aloisa Alzheimera, który przeprowadził autopsję pacjentki z objawami otępienia. Opisał on charakterystyczne zmiany patologiczne występujące w mózgu chorej, które pozwalały wyodrębnić tę chorobę spośród innych form otępienia. Zauważył obecność blaszek amyloidowych (złogów β -amyloidu) oraz splątków neurofibrylarnych zawierających hiperfosforylowe białko tau. [37]

W 1984 r. opracowano pierwsze wytyczne diagnostyczne przez *National Institute of Neurological and Communicative Disorders and Stroke* oraz grupę roboczą *Alzheimer's Disease and Related Disorders Association*. Diagnoza polegała głównie na ocenie klinicznej i poznawczej objawów otępiennych, takich jak postępujące pogorszenie pamięci, zaburzenia funkcji ruchowych, językowych i percepcyjnych, przy jednoczesnym wykluczeniu innych potencjalnych przyczyn. Jako wsparcie diagnostyczne wykorzystywano tomografię komputerową, która mogła pokazać postępujący zanik mózgu. [38]

Na przestrzeni lat dokonano znaczącego postępu w zrozumieniu przebiegu tej choroby oraz występujących wraz z nią zmian biologicznych. W odpowiedzi na rozwój wiedzy, w 2011 r. zaktualizowano wytyczne diagnostyczne, wyodrębniając trzy stadia choroby Alzheimera:

- przedkliniczne stadium choroby,
- łagodne zaburzenia poznawcze (MCI - *mild cognitive impairment*),
- pełnoobjawowe otępienie typu alzheimerowskiego.

Nowe podejście rozszerzyło proces diagnostyczny o wcześniejsze etapy rozwoju choroby, uwzględniając między innymi nowe techniki obrazowania i biomarkery biologiczne. [39]

Obecnie dane wykorzystywane w detekcji choroby Alzheimera można podzielić na następujące kategorie:

- **Testy poznawcze** - wykorzystywane do oceny funkcji poznawczych oraz wykrywania wczesnych objawów otępienia:
 - **CDR (*Clinical Dementia Rating*)** - skala kliniczna opracowana przez Johna C. Morrisa w roku 1997 do rozpoznawania otępienia typu alzheimerowskiego. Opiera się na wywiadzie z pacjentem lub opiekunem, oceniając funkcjonowanie w sześciu obszarach: pamięci, orientacji, rozwiązywania problemów, funkcjonowania społecznego, aktywności domowej oraz samodzielności i higieny osobistej. Obszary są oceniane w skali od 0 (brak zaburzeń) do 3 (znaczne zaburzenia), a globalny wynik testu wskazuje na ogólny stopień zaawansowania otępienia alzheimerowskiego. Skala została szeroko zaakceptowana w badaniach klinicznych i uznawana jest za wiarygodną i czułą metodę diagnostyczną we wczesnym rozpoznawaniu choroby Alzheimera. [42] CDR wyróżnia się wysoką skutecznością diagnostyczną: dla łagodnych zaburzeń poznawczych (MCI) osiąga czułość 93% a dla otępienia 87%. [25]
 - **CDT (*Clock Drawing Test*)**- krótki test przesiewowy oceniający zdolności wzrokowo-przestrzenne i myślenie abstrakcyjne. Polega na narysowaniu zegara z odpowiednim ustawieniem wskazówek. Ocenie podlegają zarówno poprawność wykonania zadania oraz obecność błędów poznawczych. Test wykazuje czułość 83% i specyficzność 72% w rozróżnianiu zdrowych osób od pacjentów z chorobą Alzheimera. [10]
 - **GDS (*Geriatric Depression Scale*)** - skala służąca do oceny objawów depresyjnych występujących u osób starszych. Istnieją różne warianty skali, przy czym wersja GDS-15, składająca się z 15 pytań w formie formularza z pytaniami tak/nie jest najczęściej stosowana. Wypełnienie testu trwa około 5-10 minut i nie wymaga obecności specjalisty. W badaniach wykazano, że nasilenie objawów depresyjnych mierzone GDS koreluje z przyspieszonym pogorszeniem funkcji poznawczych, progresją choroby Alzheimera z łagodnych do znacznych zaburzeń otępiennych, a także z większym odkładaniem się β -amyloidu i spadkiem metabolizmu glukozy w mózgu. [60]
 - **MMSE (*Mini-Mental State Examination*)** - test opracowany w 1975 roku jako szybka, przesiewowa metoda do oceny funkcji poznawczych. Na test składa się 11 zadań badających orientację, pamięć, zdolności wizualno-przestrzenne oraz funkcje poznawcze - razem w skali 30-punktowej. Przeprowadzenie testu trwa około 10 minut. [20] Czułość MMSE w wykrywaniu zaawansowanego otępienia wynosi 80-90%, natomiast dla łagodnych zaburzeń poznawczych (MCI) spada do 40-60%. [41]
 - **MoCA (*Montreal Cognitive Assessment*)** - narzędzie przesiewowe, które

zostało zaprojektowane jako ulepszona wersja MMSE, szczególnie pod kątem wykrywania łagodnych zaburzeń poznawczych (MCI). [12],

Opisane powyżej testy przesiewowe zostały wybrane ze względu na ich udokumentowaną wartość diagnostyczną, powszechność stosowania w praktyce klinicznej oraz istotność dla wczesnego wykrywania choroby Alzheimera. Pominęto mniej znane lub słabiej przebadane testy poznawcze.

- **Dane neuroobrazowe i neurofizjologiczne** - pozwalające na analizę struktury, funkcji i aktywności mózgu:
 - **Rezonans magnetyczny (MRI)** - nieinwazyjna, obiecująca metoda istotna dla wczesnego wykrywania choroby Alzheimera. Strukturalne obrazowanie rezonansem magnetycznym pozwala wykryć atrofię mózgu związaną z chorobą Alzheimera już w przedklinicznym stadium choroby. [57] Wykazano również, że łączenie wielu cech obrazowania MRI (objętość hipokampa i grubość kory mózgowej) poprawia dokładność rozróżniania między osobami zdrowymi, pacjentami z łagodnymi zaburzeniami poznawczymi i pacjentami chorymi. [63] Obrazy MRI mogą być uzyskiwane w różnych sekwencjach i różnią się czułością na różne właściwości tkanek. W badaniach pod kątem diagnostyki Alzheimera zazwyczaj wykorzystywane są następujące sekwencje:
 - * **T1-zależne** (*T1-weighted*) - zazwyczaj stosowane do segmentacji struktur mózgu, ponieważ dobrze pokazują szczegóły anatomiczne.
 - * **T2-zależne** (*T2-weighted*) - bardziej czułe na obecność zmian patologicznych w mózgu jak odkładanie blaszek amyloidowych.
 - **Pozytonowa tomografia emisyjna (PET)** - z radioizotopem amyloidu PiB (pozwalającym na wizualizację blaszek amyloidowych) oraz FDG-PET (do oceny metabolizmu glukozy w strukturach mózgu) Dzięki FDG-PET można z wysoką czułością wykrywać wczesne zmiany neurodegeneracyjne; niemniej jednak jest to metoda inwazyjna oraz kosztowna, co dyskwalifikuje ją jako potencjalne badanie przesiewowe. [53]
 - **Tomografia komputerowa (CT)** - nieinwazyjna, dostępna metoda obrazowania mózgu. Pomiary struktur płata skroniowego widoczne w obrazie mogą być wskaźnikiem rozróżniającym pacjentów chorych na Alzheimera od zdrowych. [62] W kontekście diagnostyki tej choroby uważana jest za mniej dokładną niż MRI czy PET. [59]
 - **EEG - elektroencefalografia** - nieinwazyjna, dostępna metoda neurofizjologiczna do oceny bioelektrycznej aktywności mózgu. U pacjentów z chorobą Alzheimera obserwuje się charakterystyczne zmiany - zmniejszenie złożoności sygnału i zwiększenie mocy w pasmach delta i theta. W porównaniu do metod neuroobrazowych, takich jak MRI czy PET, wykazuje się niższą dokładnością diagnostyczną. [15]

- **Biomarkery w płynie mózgowo-rdzeniowym:**

- $A\beta$ -amyloid (zwłaszcza izoforma $A\beta_{42}$)- obniżone stężenie tego peptydu w płynie mózgowo-rdzeniowym wiązane jest z odkładaniem płytek amyloidowych w mózgu, co jest charakterystyczną cechą patologiczną dla choroby Alzheimer’a,
- fosforylowe białko tau (fosfo-tau) - podwyższony poziom p-tau w CSF koreluje z progresją choroby Alzheimer’a oraz nasileniem się objawów poznawczych,
- całkowite białko tau (t-tau) - wzrost jego stężenia wskazuje na degenerację i uszkodzenie neuronów.

Zastosowanie kombinacji tych trzech podstawowych wskaźników ($A\beta_{42}$, p-tau i t-tau) z CSF pozwala na otrzymanie wyższej trafności diagnostycznej niż stosowanie każdego z osobna. W badaniu Hulstaerta [26] wykazano, że połączenie tych biomarkerów pozwoliło na rozróżnienie pacjentów z chorobą Alzheimer’a od zdrowych osób z czułością 85% i specyficznością 86%.

Markery te możliwe są do pobrania również nieinwazyjnie, bezpośrednio z krwi, jednak ich stężenia trudniej jednoznacznie korelować z występowaniem choroby Alzheimer’a. [51]

- **Informacje genetyczne** - obejmujące obecność mutacji w genach związanych z chorobą Alzheimer’a:

- APOE (allel $\epsilon 4$ genu apolipoproteiny E) znacząco zwiększa ryzyko zachorowania na późnoobjawową postać Alzheimer’a oraz wiązany jest z wcześniejszym początkiem objawów otępienia,
- APP (*amyloid precursor protein*) - mutacje tego genu prowadzą do nadprodukcji peptydu $A\beta_{42}$, który odpowiada za tworzenie złogów amyloidowych w mózgu,
- PSEN1 (*presenilina 1*) i PSEN2 (*presenilina 2*) - mutacje tych genów wpływają na nieprawidłowe przetwarzanie białka APP i zwiększają ilość $A\beta_{42}$. Mutacje genu PSEN1 są częstą przyczyną występowania wczesnej i dziedzicznej formy choroby Alzheimer’a.

Markery genetyczne, mimo że stają się coraz bardziej dostępne, nadal są kosztowne i nie są stosowane jako badanie przesiewowe. Ich aktualne zastosowanie to diagnostyka choroby Alzheimer’a w rodzinach obciążonych tą chorobą. [29]

W celu uporządkowania omawianych typów danych, przygotowano dwa zestawienia - osobno w ujęciu klinicznym i informatycznym. Tabela 2.1 porównuje źródła danych wykorzystywanych przy detekcji choroby Alzheimer’a pod kątem ich przydatności do wczesnego wykrywania choroby, natomiast tabela 2.2 przedstawia ich charakterystykę informatyczną.

Dane te różnią się pod względem inwazyjności, kosztu pozyskania, dostępności klinicznej, czasu potrzebnego na analizę oraz dokładności diagnostycznej. Z perspektywy badań informatycznych, szczególne znaczenie ma dobór takich typów danych, które pozwalają osiągnąć zadowalającą skuteczność klasyfikacji, przy jednoczesnym zachowaniu niskiego kosztu i praktyczności zastosowania w rzeczywistych warunkach klinicznych.

Tabela 2.1: Porównanie wybranych metod diagnostycznych choroby Alzheimera w ujęciu klinicznym (opracowanie własne)

Metoda	Inwazyjność	Koszt	Dostępność	Czas pozyskania	Zastosowanie przesiewowe / Dokładność
MMSE, MoCA	Nieinwazyjna	Niski	Wysoka	5-15 min	Tak / Średnia
CDR	Nieinwazyjna	Niski	Wysoka	15-30 min	Tak / Wysoka
CDT	Nieinwazyjna	Niski	Wysoka	5-10 min	Tak / Średnia
GDS	Nieinwazyjna	Niski	Wysoka	5-10 min	Pośrednio / Korelacja
MRI	Nieinwazyjna	Wysoki	Średnia	30-60 min + oczekiwanie	Ograniczone / Wysoka
PET	Nisko-inwazyjna	Bardzo wysoki	Ograniczona	1-2 h + oczekiwanie	Nie / Bardzo wysoka
CT	Nieinwazyjna	Średni	Średnia	15-30 min	Ograniczone / Średnia
EEG	Nieinwazyjna	Niski	Wysoka	20-30 min	Nie / Średnia
CSF	Inwazyjna	Wysoki	Ograniczona	1-2 dni + oczekiwanie	Nie / Wysoka
Biomarkery z krwi	Nieinwazyjna	Wysoki	Ograniczona	1-2 dni	Nie / Niższa niż CSF
Badania genetyczne	Nieinwazyjna	Wysoki	Ograniczona	Kilka dni	Nie / Wysoka

Tabela 2.2: Charakterystyka danych wykorzystywanych w diagnostyce choroby Alzheimera z perspektywy informatycznej (opracowanie własne)

Metoda	Format danych	Charakter danych	Uwagi techniczne
Testy poznawcze	CSV, Excel, tekst	tabelaryczne (oceny punktowe / skale)	Łatwe do standaryzacji i kodowania, niska złożoność obliczeniowa
MRI	DICOM, NIFTI	obrazy 3D, dane przestrzenne	wymaga segmentacji struktur mózgu, normalizacji przestrzennej i intensywności, wysokie wymagania obliczeniowe
PET	DICOM, NIFTI	obrazy 3D, dane przestrzenno-metaboliczne	wysokie wymagania obliczeniowe, konieczna rejestracja i analiza intensywności sygnału
CT	DICOM	obrazy 2D / 3D, dane przestrzenne	prostsze wstępne przetwarzanie, ale mniejsza rozdzielczość niż MRI
EEG	CSV, EDF, sygnały czasowe	dane czasowo-sygnałowe	wymaga przetwarzania sygnałów, filtracji, ekstrakcji cech, możliwe przetwarzane w czasie rzeczywistym
CSF	Numeryczne	dane ciągłe (stężenia biomarkerów)	proste w analizie
Biomarkery z krwi	Numeryczne	dane ciągłe	proste w analizie
Badania genetyczne	FASTQ, cechy binarne	dane sekwencyjne lub kategoryczne	wymaga bioinformatycznego przetwarzania, niezbędna redukcja wymiarowości

2.2. Podejścia oparte o jedno źródło danych w wykrywaniu choroby Alzheimera

W literaturze dotyczącej wczesnego wykrywania choroby Alzheimera opisano zarówno metody unimodalne - oparte o pojedyncze źródło danych - jak i wielomodalne - łączące więcej typów danych. Chociaż metody multimodalne wydają się bardziej obiecujące pod kątem skuteczności diagnostycznej, niebagatelne jest również przyjrzenie się podejściom unimodalnym, które ze względu na wykorzystywanie jednego typu danych, są potencjalnie tańsze i prostsze we wdrożeniu, co może mieć znaczenie dla badań przesiewowych, szczególnie

w warunkach ograniczonych zasobów.

Ze względu na dużą liczbę badań nad wykrywaniem choroby Alzheimera opartych wyłącznie na obrazach rezonansu magnetycznego (MRI), tej grupie metod poświęcono osobny podrozdział. W drugim podrozdziale zebrano pozostałe podejścia unimodalne wykorzystujące inne, wyżej opisane źródła danych.

2.2.1. Metody unimodalne oparte na obrazowaniu MRI

Wśród metod jednomodalnych, zdecydowana większość oparta jest o wykorzystanie danych z rezonansu magnetycznego (MRI), który w porównaniu do pozytonowej tomografii emisyjnej jest mniej inwazyjny, a jednocześnie wyróżnia się wyższą rozdzielczością obrazu niż tomografia komputerowa. [59]

Przetwarzanie danych MRI

Pod względem informatycznym i analitycznym dane MRI uznawane są za jedne z najbardziej wymagających typów danych medycznych. Są to dane trójwymiarowe, zwykle zapisywane w formacie DICOM. Wymagają szeregu zaawansowanych kroków przetwarzania wstępnego, a jakość tego etapu ma istotny wpływ na skuteczność dalszych analiz czy modeli uczenia maszynowego.

Popularne narzędzia stosowane do przetwarzania danych MRI:

- **FSL** (*FMRIB Software Library*) [19] - zestaw narzędzi do przetwarzania i analizy danych MRI.
- **SPM** (*Statistical Parametric Mapping*) [61] - środowisko uruchamiane w MATLAB do statystycznej analizy obrazów mózgu.
- **FreeSurfer** [36] - oprogramowanie w ramach którego można przeprowadzać automatyczną segmentację i ekstrakcję cech morfometrycznych (np. grubość kory mózgowej, objętości wybranych obszarów).
- **ANTs** (*Advanced Normalization Tools*) [5] - zestaw narzędzi do przetwarzania MRI - m. in. rejestracji i segmentacji obrazów.
- **ANTsPyNet** [47] i **FastSurfer** [16] - nowe narzędzia oparte o głębokie sieci neuronowe do szybkiej i dokładnej segmentacji struktur mózgu.
- **SimpleITK** [68] - popularna biblioteka programistyczna pomocna przy przetwarzaniu obrazów medycznych.

Standardowe kroki przetwarzania danych MRI obejmują:

- **Konwersja formatu danych** - surowe dane pochodzące ze skanera najczęściej są w formacie DICOM i zazwyczaj muszą być przekonwertowane do formatu NIfTI, który jest szeroko wspierany przez narzędzia do analizy MRI takich jak **ANTs**, **FSL**, **SPM** czy **FreeSurfer**.

- **Usunięcie tła** (*skull stripping*) - polega na wyodrębnieniu mózgu z otaczających go czaszki oraz innych tkanek miękkich. Krok ten pozwala ograniczyć dalszą analizę do istotnych struktur mózgu. Przykładowe narzędzia: FSL BET, ANTs BrainExtraction.
- **Normalizacja intensywności sygnału** (*bias field correction*) - polega na usunięciu artefaktów wynikających z nierównomiernego pola magnetycznego. Mogą one zniekształcać pomiary intensywności i prowadzić do błędów przy segmentacji tkanek. Przykładowe narzędzia to ANTs N4BiasFieldCorrection, FSL FAST.
- **Rejestracja do przestrzeni referencyjnej** (*spatial normalization*) - dopasowanie wszystkich skanów do standardowej przestrzeni (np. szablon MNI152). Proces ten umożliwia porównywanie danych między pacjentami i badaniami. Przykładowe narzędzia: ANTs, SPM, FSL FLIRT.
- **Zmiana rozdzielczości** (*resampling*) - krok służący ujednoliceniu rozmiaru wokseli dla zapewnienia spójności danych. Przykładowe narzędzia: ANTs ResampleImage, SimpleITK.
- **Wygładzanie** (*smoothing*) - polega na zastosowaniu filtrów rozmywających (np. filtr Gaussa), aby zwiększyć stosunek sygnału do szumu (SNR) oraz do poprawy jakości analiz statystycznych. Przykładowe narzędzia: SPM smooth.
- **Ekstrakcja cech** (*feature extraction*) - obejmuje wyodrębnienie np. objętości hipokampa, grubości kory mózgowej. Przykładowe narzędzia: FreeSurfer recon-all, ANTs CorticalThickness, CAT12.
- **Segmentacja** (*segmentation*) - pozwala na podział obrazu MRI na tkanki mózgowe, takie jak istota szara, istota biała i płyn mózgowo-rdzeniowy (CSF). Segmentację można przeprowadzać między innymi z wykorzystaniem metod klasycznych: FSL FAST, FreeSurfer, SPM, ANTs Atropos na podstawie map probabilistycznych lub w oparciu o uczenie maszynowe czy sieci neuronowe: FastSurfer, ANTsPyNet.

W zależności od zastosowania, dostępnych zasobów, dane kroki przetwarzania wstępnego często są pomijane lub wykonywane w odmiennej kolejności. Kluczowe jest, aby obrazy w obrębie całego zbioru, które mogą pochodzić z różnych skanerów, były w spójny sposób przetwarzane, aby nie zakłócały dalszych wyników badań.

Podejścia oparte na cechach morfometrycznych

Metody morfometryczne polegają na analizie geometrycznych i objętościowych właściwości struktur mózgu. Przykładem takich miar są grubość kory mózgowej, objętości wybranych obszarów, krzywizna czy powierzchnia kory. Cechy te pozyskiwane są najczęściej poprzez automatyczną segmentację obrazu MRI, która pozwala na identyfikację konkretnych obszarów mózgu. W kontekście choroby Alzheimera szczególną uwagę zwraca się na zanik struktur takich jak hipokamp czy ciało migdałowate oraz powiększenie komór mózgowych. [43]

Wiele badań wykorzystujących klasyczne techniki uczenia maszynowego do wykrywania choroby Alzheimera opiera się właśnie na cechach morfometrycznych wyodrębnianych przy

użyciu narzędzi takich jak FreeSurfer. Przykładem takiego podejścia jest praca Rallabandiego [52], w której zaproponowano system klasyfikacyjny dla osób zdrowych poznawczo (CN), z łagodnymi zaburzeniami poznawczymi (MCI) oraz chorych na Alzheimera (AD). Autorzy wykorzystali obrazy T1-zależne z bazy ADNI i przy pomocy FreeSurfera wyodrębnili cechy opisujące grubość kory mózgowej w wybranych regionach obu półkul mózgu. Następnie przetestowali różne klasyczne metody klasyfikacyjne: SVM, kNN, drzewa decyzyjne i naiwny klasyfikator Bayesa. Najlepsze rezultaty osiągnięto dla nieliniowego SVM z jądrem radialnym (RBF), uzyskując dokładność 75%, czułość 75% i specyficzność 77% w klasyfikacji trzech grup. Model największą trudność wykazywał przy rozróżnianiu przypadków MCI i AD, gdzie notowano zwiększony odsetek fałszywych pozytywów. Dla zwiększenia wiarygodności wyników stosowano walidację krzyżową. Mimo obiecujących rezultatów, istotną wadą podejść z użyciem narzędzia FreeSurfer jest bardzo długi czas przetwarzania danych - pełna analiza pojedynczego obrazu MRI może zajmować od kilku do nawet kilkunastu godzin w zależności od wydajności sprzętu. [35]

Podejście oparte na asymetrii struktur mózgu zaproponowali z kolei Herzog i Magoulas. [24] W ich metodzie wykorzystano różnice intensywności między półkulami do generowania tak zwanych map asymetrii. Następnie z tych map wyodrębniono cechy statystyczne (takie jak entropia, wariancja, średni błąd kwadratowy), które posłużyły jako dane wejściowe dla klasyfikatorów. Najlepsze rezultaty otrzymano przy użyciu klasyfikatora SVM z jądrem wielomianowym trzeciego stopnia (C-SVM), który osiągnął dokładność w granicach 90% dla rozróżniania między poszczególnymi klasami (CN, MCI, AD). Metoda jest lekka obliczeniowo i można ją uruchomić na standardowym sprzęcie komputerowym. Dodatkowo pojedyncze obrazy asymetrii zajmują mniej pamięci niż pełne obrazy MRI, dzięki czemu podejście to jest atrakcyjne w zastosowaniu klinicznym. Z drugiej strony jednak podejścia oparte na analizie wybranych przekrojów 2D, takie jak to, tracą aspekt przestrzenny danych, narażając na utratę istotnych informacji.

Podejścia oparte na analizie tekstury

Metody teksturalne skupiają się na badaniu lokalnych właściwości obrazu MRI - takich jak jednorodność, szorstkość czy wzorcowość rozmieszczenia intensywności sygnału. W odróżnieniu od podejść morfometrycznych, nie odnoszą się one bezpośrednio do konkretnych struktur anatomicznych, a do ogólnego charakteru tkanki mózgowej. Cechy teksturalne pozwalają na uchwycenie subtelnych zmian strukturalnych, trudnych do uchwycenia w klasycznej analizie obrazów trójwymiarowych.

Przykład takiego podejścia przedstawili Basheera i Satya Sai Rama [7], skupiając się na analizie tekstury w obrazach MRI T1- i T2-zależnych. W ramach wstępnego przetwarzania obrazów autorzy zastosowali filtrację Gaussowską oraz usunięcie tła i czaszki w celu eliminacji nieistotnych struktur i szumu. Następnie wykorzystali filtry Leung-Malik [23] do ekstrakcji cech teksturalnych z centralnych przekrojów osiowych mózgu. Wyekstrahowane cechy pogrupowano za pomocą algorytmu k-średnich, otrzymując dane wejściowe do klasyfikatorów. Badaniom poddano różne klasyczne modele algorytmów uczenia maszynowego: SVM, naiwny klasyfikator Bayesa, drzewa decyzyjne i Adaboost. Najlepsze rezultaty otrzymano dla

klasyfikatora Adaboost (z drzewem decyzyjnym jako bazowym klasyfikatorem) dla obrazów w sekwencji T2, osiągając dokładność 84,2% dla klasyfikacji AD-CN, 79,3% dla AD-MCI, co dało ogólną dokładność wieloklasową na poziomie 72,9%. Słabsze wyniki otrzymano dla klasyfikatora SVM (ok. 62%), drzew decyzyjnych ok. 67-79% i 60% dla klasyfikatora Bayesa. Pomimo obiecujących wyników, badanie to ma dwa istotne ograniczenia. Po pierwsze, rozmiar próby był stosunkowo niewielki (200 obrazów), co może ograniczać uogólnienie wyników klasyfikatora w warunkach klinicznych. Po drugie, analiza dotyczyła wyłącznie pojedynczych przekrojów dwuwymiarowych, zatem utracone zostały informacje przestrzenne zawarte w pełnych trójwymiarowych zdjęciach MRI.

Podejścia oparte na uczeniu głębokim

Uczenie głębokie (*deep learning*) staje się w ostatnich latach jednym z kluczowych podejść w analizie obrazów MRI w kontekście wczesnej diagnostyki choroby Alzheimera. Modele te, w przeciwieństwie do tradycyjnych metod uczenia maszynowego, potrafią automatycznie uczyć się reprezentacji cech bezpośrednio z danych obrazowych surowych lub uprzednio wstępnie przetworzonych. Pozwala to na wykrywanie subtelnych różnic strukturalnych w mózgu, które mogą być trudne do uchwycenia za pomocą standardowych cech.

Najwięcej metod wykrywania choroby Alzheimera opartych o uczenie głębokie stosuje splotowe sieci neuronowe (CNN), które charakteryzują się hierarchiczną strukturą warstw, co pozwala na wyodrębnianie złożonych cech z obrazów. W literaturze wyróżnia się sieci 2D CNN, 2,5D CNN i 3D CNN w zależności od charakteru danych wejściowych.

Splotowe sieci neuronowe 2D za źródło danych przyjmują pojedyncze przekroje mózgu (osiowe, koronalne lub strzałkowe). Ich zaletą są niskie wymagania obliczeniowe oraz dostępność wielu dobrze dopracowanych architektur (jak VGG16, ResNet czy AlexNet). Modele te nie wykorzystują pełnego kontekstu przestrzennego w pełnowymiarowych zdjęciach MRI, mimo to w wielu przypadkach osiągają wysoką skuteczność. Przykładowo, w pracy [11] autorzy przedstawili głęboką sieć 2D CNN wyuczoną na 15200 pojedynczych przekrojach osiowych MRI z bazy OASIS. Wykorzystano różne funkcje aktywacji (ReLU, sigmoid, tanh), dropout w celu ograniczenia przeuczenia oraz architekturę DenseNet, otrzymując ogólną skuteczność klasyfikacyjną 98%. W pracy [66] zaproponowano z kolei lekką sieć 2D CNN trenowaną od podstaw na przekrojach osiowych, koronowych i strzałkowych. Najwyższą skuteczność model uzyskał dla przekrojów strzałkowych (99,82%).

Pośrednim podejściem między analizą pojedynczych przekrojów a pełnymi woluminami MRI są modele 2,5D CNN, które przetwarzają wybrane sąsiadujące ze sobą przekroje, dzięki czemu mogą uchwycić lokalne zależności przestrzenne, zachowując stosunkowo niskie wymagania obliczeniowe w porównaniu do modeli 3D CNN. Podejście to zostało zastosowane w pracy Alloui [1], gdzie autorzy zaproponowali system wspomagający diagnozę choroby Alzheimera oparty na zmodyfikowanej sieci U-Net. Wyodrębnili sąsiadujące przekroje osiowe z obrazów MRI T1-zależnych z bazy OASIS, co pozwoliło zachować część przestrzennych informacji bez wymagań obliczeniowych sieci 3D. W modelu wykorzystano m.in. funkcję aktywacji ReLU, warstwy poolingujące i funkcję straty opartą na współczynniku Dice'a. Ostatecznie model osiągnął dokładność 92,71%, czułość 94,43% i specyficzność 91,59%. Kolejnym przykładem

wykorzystania podejścia 2,5D CNN jest praca Dai i Costen [14], gdzie autorzy przekształcili trójwymiarowe obrazy MRI w zestawy trójkanałowych obrazów RGB. Zestawy te składały się z centralnych przekrojów w płaszczyznach osiowej, koronalnej i strzałkowej z każdego trójwymiarowego zdjęcia. Ich metoda przeszkolona i testowana na danych z bazy ADNI osiągnęła ogólną dokładność 92,5%.

Modele 3D CNN przetwarzają całe wolumetryczne obrazy MRI, dzięki czemu analiza danych jest najbardziej zbliżona do rzeczywistej struktury ludzkiego mózgu. Wymagają więcej zasobów obliczeniowych, ale często osiągają bardzo wysoką skuteczność. Model taki do diagnozy choroby Alzheimera wykorzystywała między innymi autorka pracy [6]. Model osiągnął dokładność 99,2% (AD vs. CN), 87,7% (MCI vs. NC) niezależnie od różnic w protokołach akwizycji MRI oraz typów skanerów. Innym przykładem wykorzystania architektury 3D CNN jest praca [17], w której autorzy zaproponowali hybrydową neuronową sieć spłotową połączoną z klasyfikatorem SVM (3D-CNN-SVM). W badaniach porównywane były modele 2D-CNN, 3D-CNN i ich własna metoda, 3D-CNN-SVM, w której klasyfikator SVM wykorzystywano zamiast funkcji Softmax, co miało na celu zwiększenie dokładności i zapobieżenie przeuczeniu się modelu. Klasyfikator SVM z jądrem RBF (*radial basis function*) lepiej poradził sobie z separacją klas, co było szczególnie trudne w przypadku rozróżnienia klas MCI a AD. Skuteczność klasyfikacji trójklasowej tego podejścia wyniosła 95,74%.

2.2.2. Metody oparte na innych pojedynczych źródłach danych

Metody oparte na obrazowaniu PET

Kolejną liczną grupą jednomodalnych metod wykrywania choroby Alzheimera są prace oparte o pozytonową tomografię emisyjną (PET). Podobnie jak w przypadku podejść opartych o MRI, większość badań nad obrazami PET w kontekście diagnozy Alzheimera to metody oparte o spłotowe sieci neuronowe. Przykładowo, w pracy [34] zaproponowano metodę łączącą sieci spłotowe 2D z rekurencyjnymi sieciami neuronowymi. Trójwymiarowe obrazy PET podzielone zostały na przekroje 2D w różnych osiach, trenowane w ramach oddzielnych CNN. Następnie wyodrębnione cechy posłużyły za dane wejściowe do sieci RNN typu GRU, która uczyła się zależności między kolejnymi przekrojami. Wyniki z różnych osi obrazów łączono, dzięki czemu zwiększono skuteczność klasyfikacji. Osiągnięto wysokie rezultaty - ok. 91% dokładności dla rozróżnienia AD a NC oraz 78,9% dla rozróżnienia MCI a CN.

Alternatywne podejście, niezależne od uczenia głębokiego, przedstawili Silveira i Marques [55]. Autorzy zastosowali klasyfikator oparty na algorytmie Boosting do analizy intensywności voxelowej w skanach FDG-PET. Metoda ta należy do klasy algorytmów zespołowych (*ensemble learning*) i polega na łączeniu wielu prostych klasyfikatorów operujących na pojedynczych cechach. Jest to wydajne podejście w przypadku danych o bardzo wysokiej liczbie wymiarów. Analiza przeprowadzona na 268 skanach FDG-PET z bazy ADNI pozwoliła autorom na uzyskanie dokładności 90,97% w klasyfikacji AD vs. CN, 79,63% dla MCI vs. CN oraz 70% dla MCI vs. CN. Dodatkowo analiza rozmieszczenia wybranych cech (intensywności danych voxeli) wykazała ich rozproszenie w wielu regionach mózgu charakterystycznych dla zmian

neurodegeneracyjnych związanych z przebiegiem choroby Alzheimera.

Metody oparte o EEG

Równolegle prowadzone są badania nad wykorzystywaniem elektroencefalografii w kontekście wczesnej diagnozy choroby Alzheimera. W pracy [18] zaproponowano metody klasyfikacji w oparciu o drzewa decyzyjne. Sygnały EEG rejestrowano u pacjentów w stanie spoczynku z zamkniętymi oczami, wykorzystując 19 elektrod, a następnie poddano je analizie czasowo-częstotliwościowej. Ekstrakcję cech przeprowadzano dwoma różnymi sposobami: z wykorzystaniem szybkiej transformacji Fouriera (FFT) oraz dyskretnej transformacji falkowej (DWT). Lepsze wyniki uzyskano dla DWT - dokładność klasyfikacji wyniosła 91,7% dla klas NC vs. MCI, 83,3% dla NC vs. AD oraz 79,1% dla klas MCI vs. AD. Zastosowane drzewa decyzyjne umożliwiły również identyfikację najistotniejszych cech i kanałów EEG, co ma duże znaczenie w zastosowaniach klinicznych.

W pracy [27] zastosowano splotowe sieci neuronowe do klasyfikacji EEG przetworzonych metodą analizy gęstości widmowej mocy (PSD). Wyniki przedstawiono jako dwuwymiarowe obrazy w skali szarości, które stanowiły dane wejściowe dla sieci neuronowej. Autorzy uzyskali bardzo dobre wyniki klasyfikacji dla krótkich fragmentów sygnału EEG (tzw. epok), jednak zwrócili uwagę na trudności z klasyfikacją całych pacjentów. Ze względu na dużą zmienność EEG w czasie, poszczególne epoki tego samego pacjenta wskazywały na różne wyniki diagnozy, co przekładało się na obniżenie dokładności diagnozy dla pacjentów całościowo. W tabeli 2.4 uwzględniono wyniki całościowe tego badania.

Metody oparte na biomarkerach CSF

Biomarkery z płynu mózgowo-rdzeniowego w pracach często pojawiają się jako dodatkowa modalność, mniej jest prac opierających się wyłącznie o wyniki laboratoryjne CSF, a jedną z nich jest praca [33]. Autorzy tej pracy przeanalizowali skuteczność diagnozy z wykorzystaniem tradycyjnych biomarkerów CSF ($A\beta_{42}$, tau, fosforylowe tau CSF-APT) oraz rozszerzonego zestawu białek proteomicznych (CSF-RBM). Dane zostały poddane normalizacji względem wieku i płci, aby zniwelować naturalne różnice wynikające z tych ryzyk. W ramach eksperymentów testowano różne algorytmy uczenia maszynowego: SVM z jądrem liniowym i radialnym oraz Elastic Net. Wybrane modele trenowano oddzielnie na zestawach CSF-APT i CSF-RBM oraz na połączonym zestawie cech. Najwyższą skuteczność uzyskał klasyfikator SVM z jądrem liniowym trenowany na wszystkich możliwych cechach.

Metody oparte na testach poznawczych

Przykładem pracy opartej na kilku testach poznawczych ze zbiorów bazy ADNI jest praca [2], w której zbiór cech został zebrany z wyników testów ADAS-Cog, MMSE oraz FAQ, gdzie każda odpowiedź w testach była traktowana jako osobna cecha wejściowa. Autorzy zastosowali kaskadowe podejście oparte na dwóch sieciach MLP (Multilayer Perceptron), w którym pierwsza sieć odpowiadała za wyodrębnienie pacjentów zdrowych - klasyfikację CN vs. (AD + MCI), natomiast druga rozróżniała między AD i MCI. Skuteczność tej metody w

ramach wszystkich 3 klas to 82,43%.

Metody unimodalne, mimo że ograniczone do jednego źródła danych, stanowią istotny obszar badań pod kątem wczesnego wykrywania choroby Alzheimera. Ich główną zaletą jest prostsza implementacja oraz niższe wymagania obliczeniowe. Z tego względu mogą być wykorzystane jako narzędzie przesiewowe, szczególnie przy ograniczonych zasobach technicznych i finansowych. Wszystkie omówione wyżej metody wykrywania choroby Alzheimera oparte na jednym źródle danych zestawiono w rozdziale 2.5 w tabeli 2.4.

2.3. Podejścia oparte o wiele źródeł danych w wykrywaniu choroby Alzheimera

Odrębną i dynamicznie rozwijającą się gałęzią badań nad wczesną diagnostyką choroby Alzheimera są metody multimodalne, które integrują dane pochodzące z różnych źródeł. Podejścia te pozwalają na uzyskanie pełniejszego i bardziej złożonego stanu pacjenta, co ma szczególne znaczenie we wczesnych stadiach choroby Alzheimera, gdzie objawy kliniczne są subtelniejsze, a zmiany patologiczne zachodzące w mózgu mogą być nieuchwytnie w ramach jednej modalności. Jedno źródło danych zazwyczaj dostarcza ograniczoną diagnozę. Integracja pojedynczych modalności daje szansę na detekcję współistniejących wzorców strukturalnych, morfometrycznych, poznawczych, a zatem potencjalnie zwiększa skuteczność klasyfikacji oraz czułość w wykrywaniu wczesnych zmian neurodegeneracyjnych.

W literaturze istnieje wiele metod opartych na różnych kombinacjach modalności wykorzystywanych w rozpoznawaniu choroby Alzheimera. Najczęściej spotykanym podejściem multimodalnym jest integracja danych z obrazowania MRI i PET, jednak coraz więcej badań wykorzystuje szersze zestawy danych. Z informatycznego punktu widzenia wyróżnia się różne strategie integracji danych w takich modelach.

W kolejnych podrozdziałach przedstawiono strategie integracji danych wykorzystywane w klasyfikatorach opartych o wiele modalności, a następnie omówiono metody wykorzystujące standardowe kombinacje modalności dla wykrywania choroby Alzheimera.

2.3.1. Strategie fuzji danych w klasyfikatorach multimodalnych

W klasyfikatorach multimodalnych kluczowym zagadnieniem jest wybór odpowiedniej strategii integracji informacji pochodzących z różnych modalności. W kontekście diagnozy choroby Alzheimera są to wymieniane w rozdziale 2.1 źródła danych.


Jednym z powszechnie stosowanych kryteriów podziału strategii fuzji jest moment integracji danych w strukturze modelu [31]. Wyróżnia się cztery następujące podejścia:

- **Fuzja wczesna** (*early fusion*) - znana również jako fuzja na poziomie danych (*data-level fusion*), polega na połączeniu danych z wielu modalności do jednego zbioru danych jeszcze przed ekstrakcją cech. Informacje są łączone na poziomie surowych danych i później razem przetwarzane przez model. Zaletą tego podejścia jest możliwość zachowania

pełnych informacji ze wszystkich źródeł danych oraz poszukiwanie korelacji między źródłami danych. Jednocześnie podejście to wymaga ujednolicenia formatu danych i podatne jest na szum oraz nadmiarowość. W kontekście diagnozy choroby Alzheimera może to być połączenie nieprzetworzonych map intensywności z MRI i PET. Strategię fuzji wczesnej zastosowano w pracy [54].

- **Fuzja pośrednia** (*intermediate fusion*) - inaczej określana jest jako fuzja na poziomie cech (*feature-level fusion*). W tym przypadku, z każdej modalności wydobywane są najpierw cechy reprezentatywne, a dopiero później są integrowane. Podejście to pozwala łączyć cechy z różnych źródeł danych jak np. EEG + MRI bez konieczności ich uprzedniego ujednolicenia. Przykładowo, mogą to być cechy wyekstrahowane niezależnie z MRI, CSF, testów poznawczych i połączone w jedną reprezentację przed klasyfikacją. Podejście to wiąże się z większą złożonością architektury modelu. Fuzję pośrednią wykorzystano w pracach [54], [50], [56].
- **Fuzja późna** (*late fusion*) - inaczej fuzja na poziomie decyzji (*decision-level fusion*). Podejście to zakłada, że każda modalność przetwarzana jest niezależnie, a łączone są dopiero końcowe wyniki każdego z klasyfikatorów metodami takimi jak głosowanie większościowe, sumowanie ważone lub wykorzystanie meta klasyfikatora. Metoda ta zapewnia dużą elastyczność, niezależność poszczególnych architektur oraz możliwość wykorzystania wytrenowanych modeli w ramach modalności. Z drugiej strony, podejście to niesie ze sobą ryzyko pominięcia wykrycia korelacji między modalnościami. W kontekście diagnozy choroby Alzheimera mogą to być odrębne modele analizujące dane obrazowe, EEG i testy poznawcze, których predykcje łączone są w celu podjęcia ostatecznej decyzji diagnostycznej. Podejście to zastosowano w pracy [45]
- **Fuzja hybrydowa** (*hybrid fusion*) - to podejście łączące elementy dwóch lub więcej wcześniejszych strategii w ramach jednej architektury. Przykładowo, dane z MRI i PET mogą być scalone na wczesnym etapie a informacje z testów poznawczych dołączone dopiero na poziomie podejmowania decyzji diagnostycznej. Strategia ta pozwala dopasować metodę fuzji do charakterystyki danych modalności, zwiększając elastyczność i dając potencjalnie lepsze wyniki. Z drugiej strony, podejście to jest najbardziej złożone implementacyjnie.

Rodzaje strategii fuzji danych w modelach multimodalnych zostały przedstawione zbiorczo na rysunku 2.1.



Rysunek 2.1: Schemat strategii fuzji danych w klasyfikatorach multimodalnych (opracowanie własne)

2.3.2. Metody multimodalne wykrywania choroby Alzheimera

W literaturze najczęściej spotykanym podejściem multimodalnym jest połączenie danych obrazowych z rezonansu magnetycznego i pozytonowej tomografii emisyjnej. Metody oparte na tych modalnościach wykorzystują różne strategie fuzji. W pracy [54] fuzja danych odbywa się na dwóch poziomach. Najpierw zastosowano fuzję wczesną, gdzie dane obrazowe uprzednio zostały zarejestrowane do wspólnej przestrzeni i połączone na poziomie pikseli, a następnie przeprowadzono fuzję pośrednią poprzez połączenie cech wyodrębnionych oddzielnie z MRI, PET oraz obrazów połączonych, otrzymując zbiór cech strukturalnych i funkcjonalnych struktur mózgu. Finalnie dzięki fuzji cech oraz modeli zespołowych otrzymano dokładność klasyfikacji wynoszącą 99% dla klas MCI vs. CN oraz 91% dla klas AD vs. MCI. Podobne badania na MRI i PET przeprowadzili autorzy pracy [50], którzy badali, czy fuzja na poziomie cech zwiększy skuteczność metody. Fuzja została w tym przypadku przeprowadzona na poziomie architektury sieci, gdzie obrazy MRI i PET przetwarzano w równoległych gałęziach CNN, a następnie połączono ich reprezentację pośrednią. Sieć CNN łącząca te modalności osiągnęła dokładność 92,3%, przewyższając skuteczność sieci opartych na pojedynczych modalnościach.

Przykładem zastosowania fuzji na poziomie decyzyjnym w multimodalnych metodach wykrywania choroby Alzheimera jest praca [45] z 2024 roku, w której autorzy integrują trzy

różne źródła danych: biomarkery CSF, obrazy MRI oraz testy poznawcze pochodzące głównie z bazy danych OASIS. Autorzy zaproponowali trzy różne modele dla każdej modalności (sieć CNN do klasyfikacji skanów MRI, oraz sieć LSTM RNN oddzielnie dla testów poznawczych i biomarkerów CSF) i na etapie końcowym zagregowali niezależne wyniki predykcji z każdego z modeli przy użyciu średniej ważonej wyników cząstkowych. Zaletą tego podejścia jest odporność na brak prawidłowej klasyfikacji z jednego modelu oraz pozwala na uzyskanie wysokiej dokładności predykcji na poziomie 92%. Ponadto późna fuzja w tym przypadku umożliwia łatwiejszą interpretowalność wpływu poszczególnych modalności na wynik klasyfikacji.

Z neuroobrazowania zrezygnowali autorzy pracy [56], którzy stworzyli lekki model klasyfikacyjny na podstawie danych klinicznych i neuropsychologicznych (testów poznawczych) z bazy ADNI. Następnie wykorzystano algorytmy genetyczne do selekcji najbardziej istotnych cech diagnostycznych oraz klasyfikator SVM z jądrem liniowym do predykcji diagnozy pacjentów. Najbardziej znaczącymi cechami okazały się CDRSB z testu poznawczego CDR oraz MMSE spośród 927 początkowo. Model bazujący wyłącznie na tych dwóch cechach osiągnął dokładność 94,33% dla klasyfikacji binarnej AD vs. MCI+CN. W testach klasyfikatorów łączono dane, stosując fuzję pośrednią.

Inne podejście multimodalne do wczesnego wykrywania choroby Alzheimera opisano w pracy [46], w której autorzy zaproponowali metodę na podstawie trzech typów danych: neuroobrazowania MRI i PET oraz informacji genetycznych (SNP). Skany MRI i PET przetworzono wstępnie przy użyciu narzędzia SPM12, natomiast dane genetyczne z wykorzystaniem oprogramowania GenomeStudio oraz zredukowano znacznie ich wymiarowość. Również w tym badaniu przeprowadzono fuzję na poziomie łączenia cech. W ramach testowanych modeli jednomodalnych największą dokładność dawały informacje genetyczne, niemniej jednak połączenie wielu modalności znacząco poprawiło dokładność diagnozy choroby Alzheimera, a dodanie informacji genetycznych podniosło wyniki klasyfikacji o kilka punktów procentowych w porównaniu do metod opartych na MRI i PET.

Metody multimodalne wykrywania choroby Alzheimera omówione wyżej zestawiono w rozdziale 2.5 w tabeli 2.5.

2.4. Kryteria oceny skuteczności klasyfikatorów

W celu rzetelnej oceny skuteczności metod służących do wczesnego wykrywania choroby Alzheimera oraz określenia ich wartości diagnostycznej w praktyce klinicznej stosuje się szereg standardowych kryteriów klasyfikacyjnych. W kontekście medycznym szczególne znaczenie ma minimalizacja liczby błędów typu fałszywie negatywnego, czyli sytuacji, w których rzeczywiście chorzy pacjenci zostają błędnie zaklasyfikowani jako zdrowi. Takie pomyłki mogą prowadzić do opóźnienia postawienia diagnozy oraz utraty możliwości interwencji, która mogłaby spowolnić postęp choroby Alzheimera.

Dla binarnej klasyfikacji wyniki działania modelu często reprezentowane są w postaci macierzy konfuzji (2.3).

Tabela 2.3: Macierz konfuzji dla klasyfikatora binarnego

Wartości rzeczywiste	Wartości predykowane	
	Pozytywne	Negatywne
Pozytywne	Prawdziwie pozytywne (TP)	Fałszywie negatywne (FN)
Negatywne	Fałszywie pozytywne (FP)	Prawdziwie negatywne (TN)

Na podstawie wartości z macierzy konfuzji można wyznaczyć następujące metryki:

- **Dokładność (*accuracy*)** - określa ogólny stosunek prawidłowych predykcji (zarówno pozytywnych i negatywnych) do całkowitej liczby klasyfikowanych danych:

$$\text{Dokładność} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.1)$$

Jest to popularna i prosta metryka, natomiast jej wartość może być myląca w przypadku niezbalansowanych danych, gdzie np. liczba zdrowych pacjentów znacznie przewyższa liczbę chorych pacjentów.

- **Czułość (*sensitivity, recall*)** - określa stosunek liczby prawidłowo zakwalifikowanych chorych pacjentów do wszystkich rzeczywiście chorych pacjentów:

$$\text{Czułość} = \frac{TP}{TP + FN} \quad (2.2)$$

Metryka jest ta istotna w kontekście klinicznym - im wyższa jej wartość, tym mniejsze ryzyko przeoczenia przypadków choroby, co jest szczególnie istotne dla wczesnej diagnostyki choroby Alzheimera.

- **Swoistość - (*specificity*)** - określa, jaka część zdrowych pacjentów została prawidłowo zakwalifikowana jako zdrowi pacjenci:

$$\text{Swoistość} = \frac{TN}{TN + FP} \quad (2.3)$$

Z punktu medycznego wysoka swoistość pozwala ograniczyć liczbę niepotrzebnych badań dla fałszywie zakwalifikowanych chorych pacjentów oraz zmniejszyć ich obciążenie psychiczne.

- **Precyzja - (*precision*)** - wskazuje, jaka część chorych pacjentów faktycznie nimi jest:

$$\text{Precyzja} = \frac{TP}{TP + FP} \quad (2.4)$$

- **Miara F1 - (*F1-score*)** - średnia harmoniczna precyzji i czułości:

$$F1 = 2 \cdot \frac{\text{Precyzja} \cdot \text{Czułość}}{\text{Precyzja} + \text{Czułość}} \quad (2.5)$$

Miara F1 znajduje zastosowanie szczególnie dla niezbalansowanych zbiorów danych, ponieważ równoważnie bierze pod uwagę liczbę błędnie pominiętych chorych oraz błędnie zdiagnozowanych chorych.

Dodatkowym kryterium oceny skuteczności modeli, często występującym w analizowanych w kolejnych rozdziałach pracach, jest **AUC** (*Area Under the Curve*) - pole pod krzywą **ROC** (*Receiver Operating Characteristic*). Metryka ta określa zdolność modelu do rozróżniania między klasami niezależnie od przyjętego progu decyzyjnego. Krzywa ROC obrazuje zależność między czułością a odsetkiem fałszywie pozytywnych wyników. Wartość AUC-ROC przyjmuje wartości od 0 do 1, gdzie 1 oznacza doskonałą klasyfikację, a wartość 0,5 odpowiada klasyfikacji losowej (w przypadku klasyfikacji binarnej). Im wyższa wartość AUC-ROC, tym większa zdolność modelu do prawidłowej klasyfikacji.

W literaturze dotyczącej wczesnej diagnozy choroby Alzheimera najczęściej stosowaną metryką skuteczności modeli jest dokładność. W niektórych publikacjach autorzy przedstawiają również dokładność modelu obliczaną osobno dla każdej klasy, co pozwala na bardziej szczegółową ocenę rozróżniania modelu pomiędzy poszczególnymi stanami klinicznymi. Rzadziej raportowane są czułość i swoistość, mimo że mają kluczowe znaczenie w zastosowaniach medycznych. W szczególności czułość jest krytyczna dla wczesnej diagnostyki choroby Alzheimera, ponieważ wczesne wykrycie przypadków MCI (łagodne zaburzenia poznawcze) oraz AD (choroba Alzheimera) pozwala na wprowadzenie leczenia spowalniającego progres choroby.

2.5. Wnioski z przeglądu literatury

Choroba Alzheimera, mimo że opisana była już w 1906 roku, wciąż stanowi duże wyzwanie diagnostyczne dla współczesnej medycyny. W niniejszym przeglądzie przedstawiono aktualny stan wiedzy w zakresie podejść do wykrywania choroby Alzheimera wykorzystujących uczenie maszynowe i sztuczną inteligencję, które dynamicznie rozwijają się oraz wykazują potencjał praktyczny we wdrożeniach klinicznych.

W pierwszej kolejności przedstawiono szerokie spektrum aktualnie wykorzystywanych danych w diagnostyce choroby Alzheimera: testy poznawcze (CDR, CDT, GDS, MMSE, MoCA), dane neuroobrazowe (MRI, PET, CT), sygnały neurofizjologiczne (EEG), biomarkery płynowe (z CSF i krwi) oraz dane genetyczne.

Metody diagnostyczne z wykorzystaniem pojedynczego źródła, choć wykazywały dużą dokładność diagnostyczną, wiążą się z istotnymi ograniczeniami. Testy poznawcze, choć tanie i łatwe do wdrożenia, nie pozwalają jednoznacznie wykluczyć innych przyczyn otępienia niż choroba Alzheimera. Elektroencefalografia cechuje się niskim kosztem i dużą dostępnością, ale jej dokładność diagnostyczna jest niska i nie dorównuje technikom obrazowym. Metody wykorzystujące biomarkery z płynu mózgowo-rdzeniowego są jednocześnie inwazyjne i wiążą się z wysokimi kosztami badań, co ogranicza ich użyteczność w badaniach przesiewowych. Najwyższą skuteczność osiągają metody oparte na neuroobrazowaniu, w szczególności MRI i PET. MRI ze względu na nieinwazyjność oraz wysoką rozdzielczość danych, stanowi najczęściej wykorzystywane źródło danych w badaniach naukowych. Najlepsze wyniki klasyfikacyjne dla MRI osiągają modele głębokiego uczenia, w szczególności sieci splotowe, które umożliwiają automatyczną ekstrakcję cech bez konieczności ręcznego przetwarzania obrazów, co jest bardzo czasochłonne.

Podsumowanie metod unimodalnych przedstawiono w tabeli 2.4, gdzie zestawiono typy danych, licznosc próby, na której przeprowadzano badania, wykorzystane modele oraz osiągnięte wyniki klasyfikacji.

Tabela 2.4: Przegląd wybranych jednomodalnych metod wykrywania choroby Alzheimera z wykorzystaniem różnych źródeł danych i modeli informatycznych (opracowanie własne)

Ref.	Typ danych	Liczność próby	Model	Dokładność (%)		Czułość (%)		Specyficzność (%)		AUC-ROC	
[52]	MRI	1167 obrazów	C-SVM	75,0		75,0		77,0		0,76	
[24]	MRI	750 pacjentów	RBF-SVM	AD/CN:	93,0	AD/CN:	93,0	AD/CN:	93,0	AD/CN:	0,99
				MCI/CN:	92,5	MCI/CN:	95,0	MCI/CN:	90,0	MCI/CN:	0,98
				AD/MCI:	86,5	AD/MCI:	88,0	AD/MCI:	85,0	AD/MCI:	0,94
[7]	MRI	200 obrazów	Adaboost	AD/CN:	84,2	—		—		—	
				AD/MCI:	79,3						
[11]	MRI	15 200 obrazów	2D CNN	98,0		AD:	90,2	—		0,98	
						MCI:	93,8				
						CN:	86,6				
[66]	MRI	70 pacjentów	2D CNN	99,8		AD:	100,0	AD:	99,7	—	
						MCI:	99,8	MCI:	99,9		
						CN:	99,7	CN:	99,8		
[1]	MRI	126 pacjentów	2,5D CNN	92,7		94,4		91,6		—	
[14]	MRI	90 pacjentów	2,5D CNN	92,5		91,0		97,0		—	
[6]	MRI	1638 pacjentów	3D CNN	AD/CN:	99,2	AD/CN:	98,9	AD/CN:	99,5	—	
				MCI/CN:	87,1	MCI/CN:	87,8	MCI/CN:	86,5		
				AD/MCI:	75,4	AD/MCI:	74,5	AD/MCI:	76,4		
[17]	MRI	469 pacjentów	3D CNN, SVM	AD/CN:	99,1	AD/CN:	99,8	AD/CN:	98,4	AD/CN:	0,99
				MCI/CN:	98,9	MCI/CN:	98,9	MCI/CN:	98,8	MCI/CN:	0,99
				AD/MCI:	89,4	AD/MCI:	86,7	AD/MCI:	84,0	AD/MCI:	0,93
[34]	PET	339 pacjentów	3D CNN + RNN	AD/CN:	91,2	AD/CN:	91,4	AD/CN:	91,0	AD/CN:	0,95
				MCI/CN:	78,9	MCI/CN:	78,1	MCI/CN:	80,0	MCI/CN:	0,83
[55]	PET	268 pacjentów	Boosting	AD/CN:	91,0	—		—		—	
				MCI/CN:	79,6						
				AD/MCI:	70,0						
[18]	EEG	109 pacjentów	Drzewo decyzyjne	AD/CN:	83,3	AD/CN:	83,3	AD/CN:	78,0	—	
				MCI/CN:	91,7	MCI/CN:	91,7	MCI/CN:	91,5		
				AD/MCI:	79,1	AD/MCI:	79,1	AD/MCI:	79,1		
[27]	EEG	189 pacjentów	2D CNN	AD/NC:	79,2	AD/NC:	95,8	AD/NC:	62,5	—	
				AD/MCI:	45,8	AD/MCI:	45,8	AD/MCI:	45,8		
				MCI/NC:	62,5	MCI/NC:	75,0	MCI/NC:	50,0		
[33]	CSF	304 pacjentów	SVM liniowy	AD/CN:	81,5	—		—		AD/CN:	0,92
				MCI/CN:	64,3					MCI/CN:	0,71
				AD/MCI:	59,0					AD/MCI:	0,59
[2]	Testy poznawcze	808 pacjentów	MLP	AD/CN:	99,3	AD/CN:	98,0	AD/CN:	100,00	AD/CN:	1,00
				MCI/CN:	90,2	MCI/CN:	90,8	MCI/CN:	89,1	MCI/CN:	0,96
				AD/MCI:	89,5	AD/MCI:	81,4	AD/MCI:	93,4	AD/MCI:	0,96

Metody multimodalne, integrujące dane z różnych źródeł, wykazują wyższą dokładność i lepszą zdolność do wykrywania subtelnych zmian, szczególnie istotnych w przypadku pacjentów z łagodnymi zaburzeniami poznawczymi (MCI). Pozwalają uchwycić współistniejące zmiany strukturalne, funkcjonalne i poznawcze, które mogą być niezauważalne dla metod opartych na pojedynczej modalności. Podejścia te z drugiej strony są trudniejsze do wdrożenia, nierzadko droższe, co ogranicza ich praktyczność w rzeczywistych warunkach klinicznych.

Najwięcej badań w tej grupie powstało na podstawie fuzji danych ze skanów MRI i PET. Metody te wykazują wysoką dokładność, ale opierają się na dwóch kosztownych źródłach danych, przez co nie nadają się do celów przesiewowych. Kluczową rolę odgrywa również strategia fuzji danych. Najlepsze rezultaty zaobserwowano w przypadku podejść opartych na fuzji pośredniej lub późnej, które jednocześnie umożliwiają lepszą interpretowalność wyników. Zestawienie wybranych podejść multimodalnych przedstawiono w tabeli 2.5 z uwzględnieniem wybranych źródeł danych, liczności próby, zastosowanych modeli oraz osiągniętych wyników klasyfikacji.

Tabela 2.5: Przegląd wybranych wielomodalnych metod wykrywania choroby Alzheimera z wykorzystaniem różnych źródeł danych i modeli informatycznych (opracowanie własne)

Ref.	Typ danych	Liczność próby	Model	Dokładność (%)	Czułość (%)	Specyficzność (%)	AUC-ROC
[54]	MRI, PET	600 obrazów	Klasyfikator zespołowy	AD/CN: 99,0 MCI/CN: 99,0 AD/MCI: 91,0	—	—	—
[50]	MRI, PET	585 obrazów	CNN	92,3	—	—	—
[45]	MRI, testy poznawcze, CSF	od 416 do 3000 pacjentów w zależności od modelu	CNN, LSTM, RNN	92,1	91,2	—	0,95
[56]	Testy poznawcze, dane kliniczne	106 pacjentów	SVM, algorytm genetyczny	AD: 94,3	AD: 77,2	AD: 98,1	AD: 0,88

Przy przeglądzie kryteriów oceny skuteczności klasyfikatorów podkreślono znaczenie stosowania nie tylko metryki dokładności, ale również czułości i AUC-ROC, które są istotne w kontekście medycznym, a zwłaszcza minimalizacji liczby fałszywie negatywnych przypadków.

Podsumowując, przeprowadzony przegląd literatury pozwolił na udzielenie odpowiedzi na postawione na początku rozdziału pytania badawcze. Wykazano, że dostępne typy danych wykorzystywane w diagnostyce choroby Alzheimera różnią się pod względem inwazyjności, dostępności oraz skuteczności diagnostycznej. Spośród metod jednomodalnych najwyższą skuteczność osiągają podejścia oparte na danych neuroobrazowych (MRI, PET). Metody multimodalne są obiecującym kierunkiem badań nad wczesnym wspomaganem diagnozy choroby Alzheimera. Zapewniają one wyższą skuteczność diagnostyczną, ponieważ potrafią

uchwycić współistniejące zmiany między różnymi źródłami danych, jednak ich koszt i złożoność mogą ograniczać możliwość zastosowania ich w codziennej praktyce medycznej. Przegląd stosowanych metryk pokazał, że szczególnie istotne w praktyce klinicznej jest minimalizowanie ryzyka przeoczenia choroby i znaczenie wysokiej czułości.

Z przeanalizowanych badań w ramach niniejszego przeglądu wynika, że istnieje potrzeba opracowania nowych rozwiązań, które łączyłyby wysoką skuteczność diagnostyczną z niską inwazyjnością, przystępnością kosztową i łatwą dostępnością danych. Szczególnie obiecujące wydaje się podejście oparte na tanich, nieinwazyjnych źródłach danych (takich jak testy poznawcze czy EEG), które mogłyby stanowić etap przesiewowy metody. W przypadkach wymagających dalszej weryfikacji możliwe byłoby przeprowadzenie pogłębionej analizy z wykorzystaniem bardziej zaawansowanych metod (takich jak np. MRI czy PET), co pozwoliłoby zachować równowagę między skutecznością a praktycznością wdrożenia w systemie opieki zdrowotnej.